Презентация работы на конференции



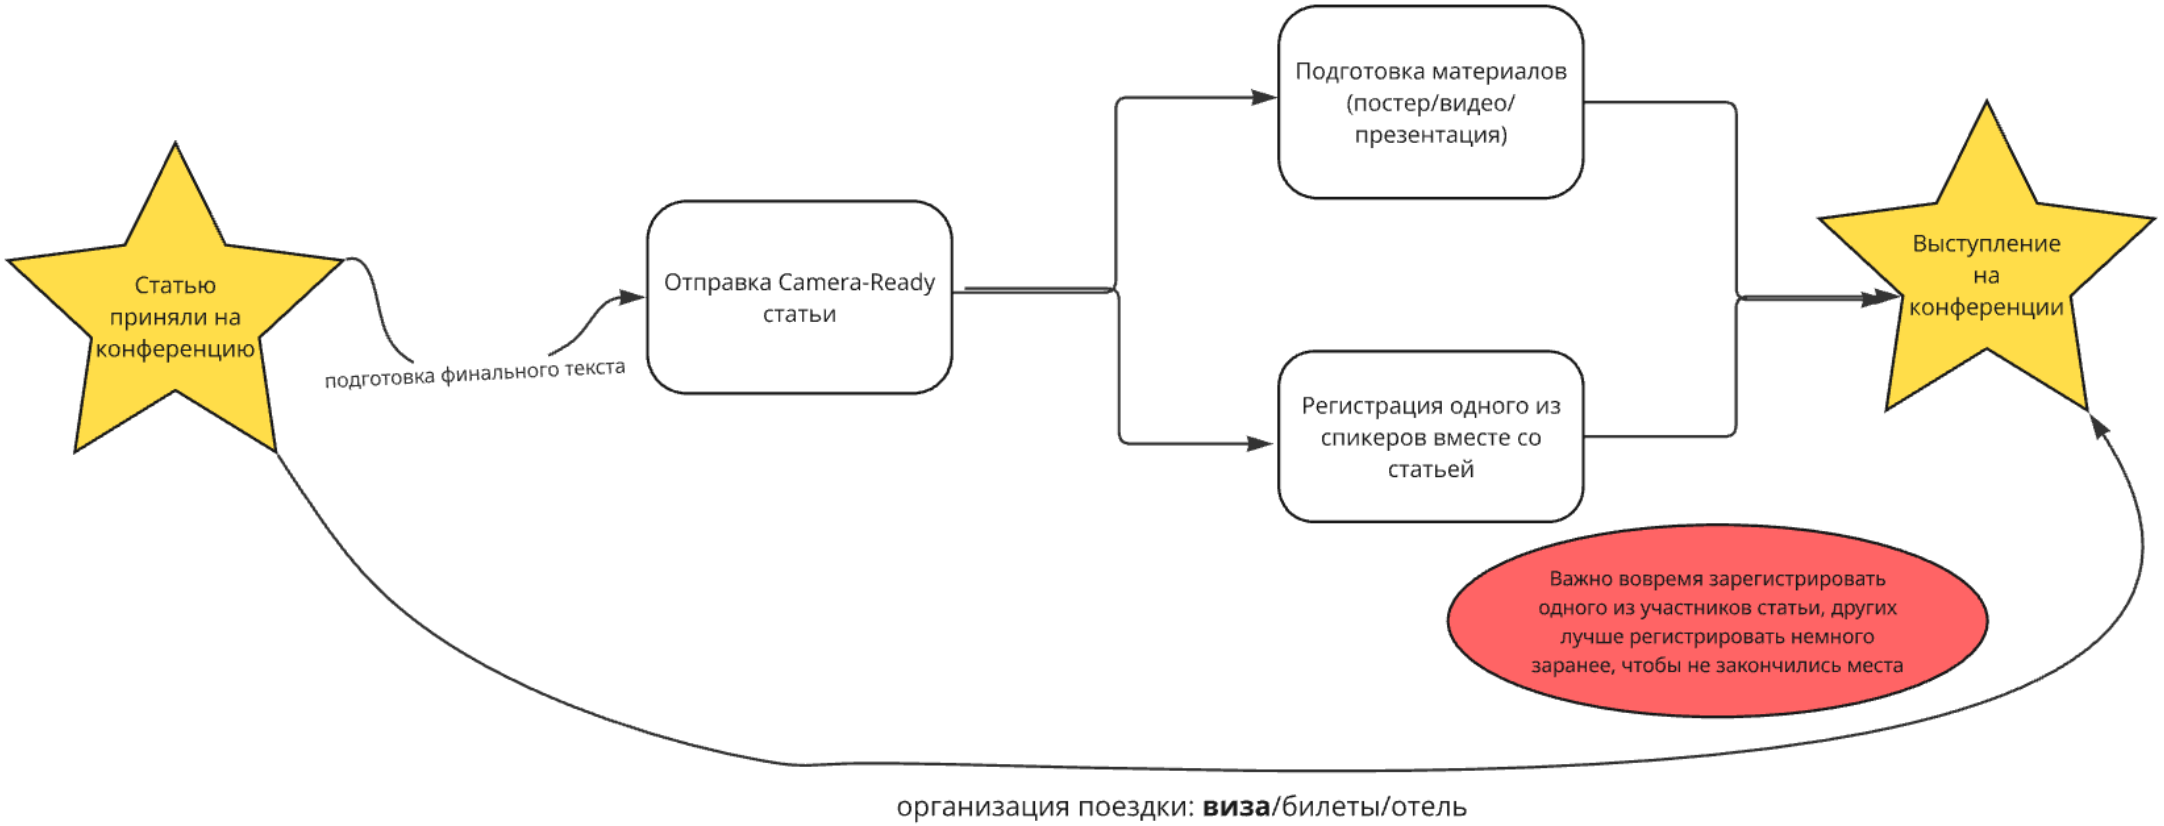
Мария Тихонова
Руководитель Research кластера
Доцент ВШЭ

План

- Ключевые этапы подготовки к конференции после принятия статьи
- Что поменять в camera-ready статье?
- Как сделать хороший постер и видео?
- Что включает презентация постера?
- Какие дедлайны нельзя пропустить?



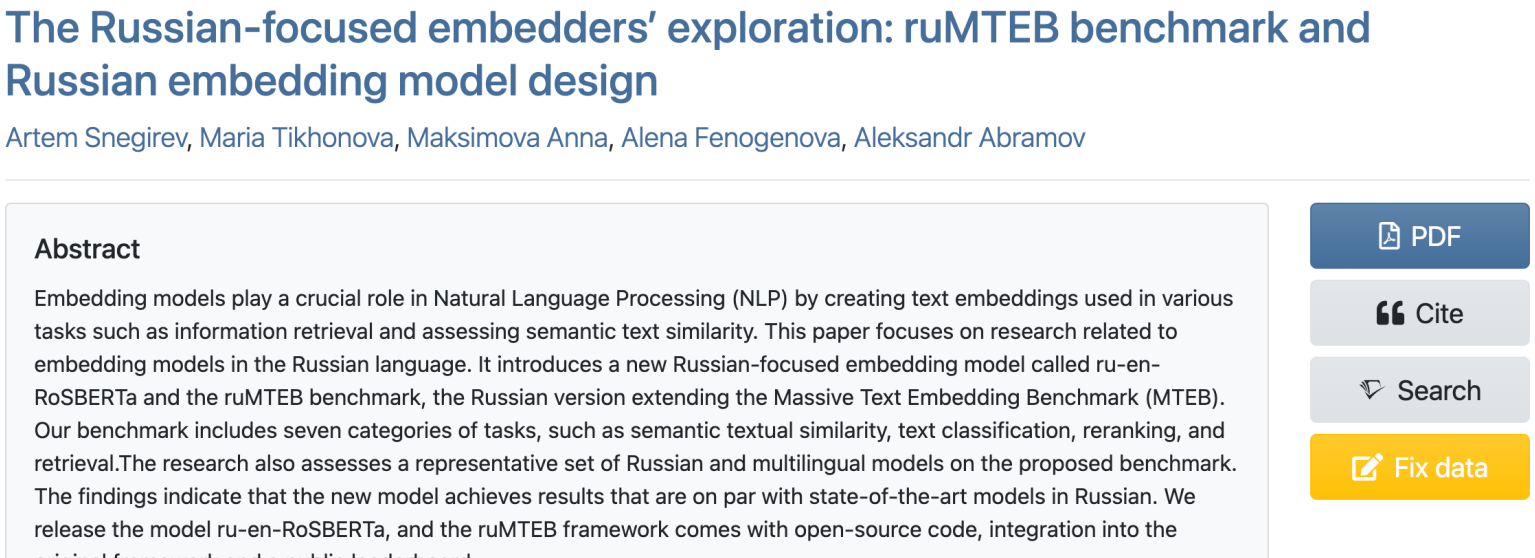
Подготовка статьи и выступления на конференцию



Подготовка camera-ready

Camera-ready — финальная деанонимизированная версия статьи для публикации:

- деанонимизированная
- исправленная по итогам ревью
- + 1 дополнительная страница (чаще всего) на то, чтобы учесть комментарии



The Russian-focused embedders' exploration: ruMTEB benchmark and Russian embedding model design

Artem Snegirev, Maria Tikhonova, Maksimova Anna, Alena Fenogenova, Aleksandr Abramov

Abstract

Embedding models play a crucial role in Natural Language Processing (NLP) by creating text embeddings used in various tasks such as information retrieval and assessing semantic text similarity. This paper focuses on research related to embedding models in the Russian language. It introduces a new Russian-focused embedding model called ru-en-RoSBERTa and the ruMTEB benchmark, the Russian version extending the Massive Text Embedding Benchmark (MTEB). Our benchmark includes seven categories of tasks, such as semantic textual similarity, text classification, reranking, and retrieval.The research also assesses a representative set of Russian and multilingual models on the proposed benchmark. The findings indicate that the new model achieves results that are on par with state-of-the-art models in Russian. We release the model ru-en-RoSBERTa, and the ruMTEB framework comes with open-source code, integration into the

PDF

Cite

Search

Fix data

Чек-лист camera-ready

```
% Change "review" to "final" to generate the final (sometimes called camera-ready) version.
% Change to "preprint" to generate a non-anonymous version with page numbers.
\usepackage[review]{acl}
```

Чек-лист:

- деанонимизировать
  - поменять «review» на «final» в overleaf для *CL конференций
  - добавить авторов
  - добавить ссылки на реп/код/проект
  - добавить раздел благодарностей (acknowledgements) после Conclusion
- **внести комментарии метаревьюера (насколько возможно):**
  - можно вносить небольшие дополнения
  - нельзя сильно менять статью
- **отправить в систему до дедлайна**



.



Повторного ревью нет и проверки, что правки учтены нет.
НО!
Это ваше «лицо» как исследователя!

Подготовка материалов



Материалы для конференции

Что презентуют на конференции:

- короткое предзаписанное видео (default)
- постер (most common)
- устный доклад, он же oral (less common)
- + [Demo only] демонстрация системы (сайт/система на ноутбуке)

Точный формат выступления зависит от:

- конференции/воркшопа
- трека статьи
- оценок вашей статьи



.



Не пропустите дедлайн отправки материалов, иначе статью не опубликуют!

Прим. Обычно дедлайн отправки на конференцию неожиданно и невовремя присылают на почту

Предзаписанное видео

Предзаписанное видео — визитка вашей статьи. Его выкладывают на платформу с вашим докладом.

Исследователи, которым интересная ваша тема в первую очередь смотрят его.



Формат:

- обычно 5-12 минут (точный тайминг зависит от конференции и трека)
- язык видео и слайдов — АНГЛИЙСКИЙ
- шаблона нет, лучше нейтральный
- бывают ограничения на объем/формат видеозаписи
- дополнительно можно приложить слайды



Предзаписанное видео



Чек-лист подготовки:

- подготовьте слайды (обычно не более 8-15)
  - старайтесь отразить основную суть и результаты
  - не впихивайте все
  - прогоните через LLM на проверку орфографии
- **напишите текст скрипта**
  - неподготовленная речь на английском на видео смотрится коряво
  - позволяет избежать слов-паразитов
  - оговорки в записи не поправить, а путать мелочи не хочется
- выберите способ записи
  - запись вас на камеру + добавить слайды на монтаже
  - запись через zoom/telemost/запись экрана
- **выделите время на съемку**
  - минимум 1 час времени
  - **тихое место**
  - хороший дневной свет/лампа освещающая лицо
  - нет посторонних шумов
- смонтируйте
  - обрежьте лишнее
  - наложите. повторно слайды







Видео – это ваша визитка! Его смотрят участники конференции. Не пренебрегайте качеством!

Предзаписанное видео



Чек-лист съемки:

- минимум 1 час времени
- **тихое место без шумов**
- настройте максимальное разрешение записи (Zoom/Telemost/MTS Link)
- хороший дневной свет/лампа, освещающая лицо
- сделайте тестовый дубль
- проверьте качество звука в записи
- проверьте, что ваша голова не закрывает текст в записи
- при чтении расположите текст строго под камерой => не видно движение глаз

.

Варианты записи:

- **simple:** одним кадром
- **medium:** несколько фрагментов + склеить в любом редакторе
- **advanced:** записать пофрагментно видео + наложить на скрины слайдов

Постер

Overleaf VS Figma



Обращайте внимание на размер:

- как правило A0
- горизонтальный или вертикальный
- лучше матовый

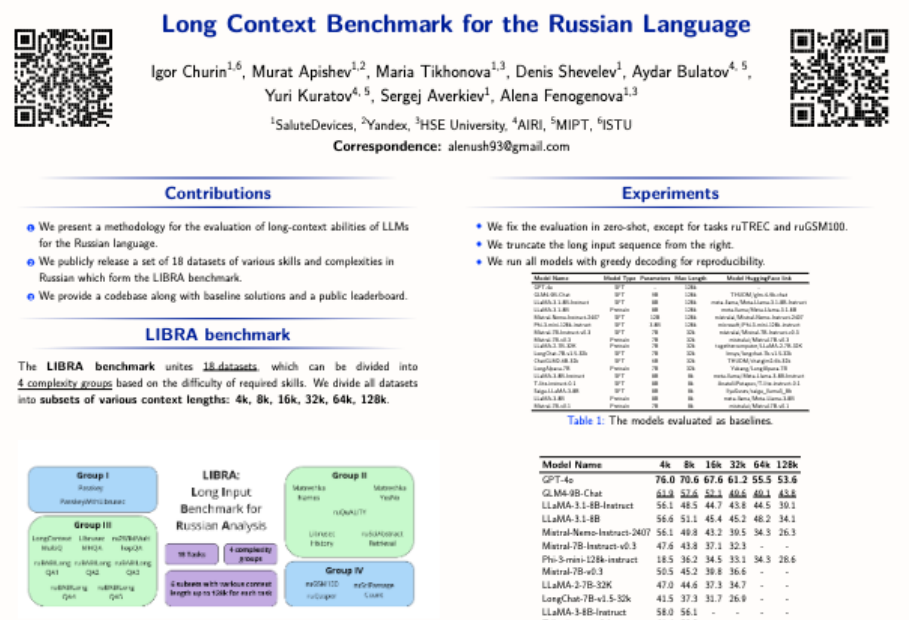
Постер

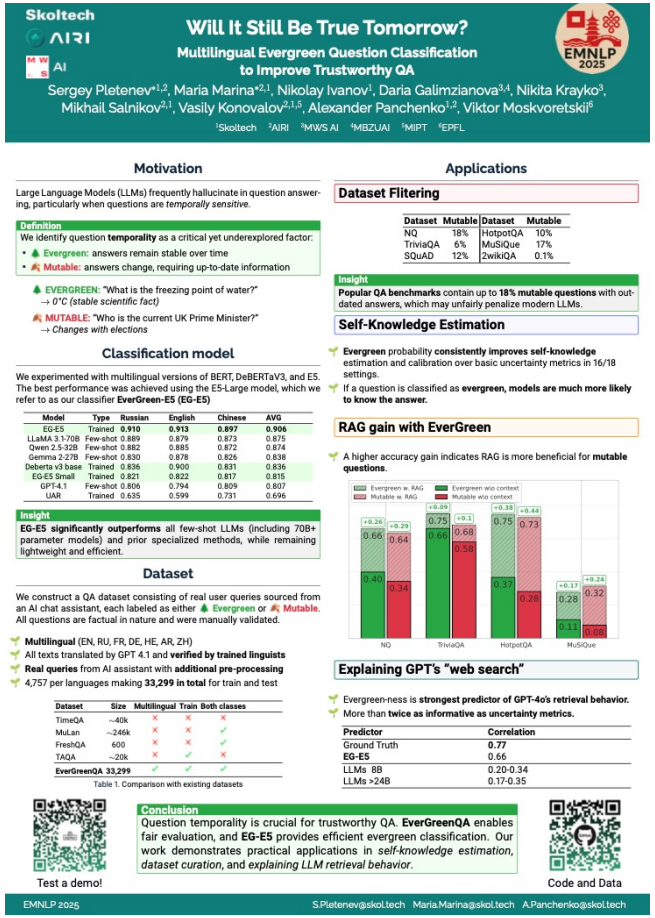


Рекомендации:

- возьмите хороший образец
- пишите тезисно
- берите за основу статью
- QR-код на статью/работу (прямо в LaTeX)
- хорошее разрешение картинок
- используйте LLM для дебага (ChatGPT/DeepSeek)
- лого конференции

.





https://www.overleaf.com/learn/latex/Beamer

Путь сильных — vibe coding макета в beamer

- Отправляем текст статьи в LLM
- Описываем, что хотим видеть на постере
- Дорабатываем

Постер: пример

Long Context Benchmark for the Russian Language

Igor Churin[1,6], Murat Apishev[1,2], Maria Tikhonova[1,3], Denis Shevelev[1], Aydar Bulatov[4,5], Yuri Kuratov[4,5], Sergej Averkiev[1], Alena Fenogenova[1,3]

[1]SaluteDevices, [2]Yandex, [3]HSE University, [4]AIRI, [5]MIPT, [6]ISTU

Correspondence: alenush93@gmail.com

Contributions

1. We present a methodology for the evaluation of long-context abilities of LLMs for the Russian language.
2. We publicly release a set of 18 datasets of various skills and complexities in Russian which form the LIBRA benchmark.
3. We provide a codebase along with baseline solutions and a public leaderboard.

LIBRA benchmark

The **LIBRA benchmark** unites 18 datasets, which can be divided into 4 complexity groups based on the difficulty of required skills. We divide all datasets into **subsets of various context lengths: 4k, 8k, 16k, 32k, 64k, 128k**.



Figure 1: The scheme of the LIBRA benchmark presenting all benchmark tasks divided into 4 complexity groups.

Experiments

- We fix the evaluation in zero-shot, except for tasks ruTREC and ruGSM100.
- We truncate the long input sequence from the right.
- We run all models with greedy decoding for reproducibility.

Model Name	Model Type	Parameters	Max Length	Model HuggingFace link
GPT-4o	SFT		128k	
GLM4-9B-Chat	SFT	9B	128k	THUDM/glm-4-9b-chat
LLaMA-3.1-8B-Instruct	SFT	8B	128k	meta-llama/Meta-Llama-3.1-8B-Instruct
LLaMA-3.1-8B	Pretrain	8B	128k	meta-llama/Meta-Llama-3.1-8B
Mistral-Nemo-Instruct-2407	SFT	12B	128k	mistralai/Mistral-Nemo-Instruct-2407
Phi-3-mini-128k-instruct	SFT	3.8B	128k	microsoft/Phi-3-mini-128k-instruct
Mistral-7B-Instruct-v0.3	SFT	7B	32k	mistralai/Mistral-7B-Instruct-v0.3
Mistral-7B-v0.3	Pretrain	7B	32k	mistralai/Mistral-7B-v0.3
LLaMA-2-7B-32K	Pretrain	7B	32k	togethercomputer/LLaMA-2-7B-32K
LongChat-7B-v1.5-32k	SFT	7B	32k	lmsys/longchat-7b-v1.5-32k
ChatGLM2-6B-32k	SFT	6B	32k	THUDM/chatglm2-6b-32k
LongAlpaca-7B	Pretrain	7B	32k	Yukang/LongAlpaca-7B
LLaMA-3-8B-Instruct	SFT	8B	8k	meta-llama/Meta-Llama-3-8B-Instruct
T-lite-instruct-0.1	SFT	8B	8k	AnatoliiPotapov/T-lite-instruct-0.1
Saiga-LLaMA-3-8B	SFT	8B	8k	IlyaGusev/saiga_llama3_8b
LLaMA-3-8B	Pretrain	8B	8k	meta-llama/Meta-Llama-3-8B
Mistral-7B-v0.1	Pretrain	7B	8k	mistralai/Mistral-7B-v0.1

Table 1: The models evaluated as baselines.

Model Name	4k	8k	16k	32k	64k	128k
GPT-4o	**76.0**	**70.6**	**67.6**	**61.2**	**55.5**	**53.6**
GLM4-9B-Chat	61.9	57.6	52.1	49.6	49.1	43.8
LLaMA-3.1-8B-Instruct	56.1	48.5	44.7	43.8	44.5	39.1
LLaMA-3.1-8B	56.6	51.1	45.4	45.2	48.2	34.1
Mistral-Nemo-Instruct-2407	56.1	49.8	43.2	39.5	34.3	26.3
Mistral-7B-Instruct-v0.3	47.6	43.8	37.1	32.3	-	-
Phi-3-mini-128k-instruct	18.5	36.2	34.5	33.1	34.3	28.6
Mistral-7B-v0.3	50.5	45.2	39.8	36.6	-	-
LLaMA-2-7B-32K	47.0	44.6	37.3	34.7	-	-
LongChat-7B-v1.5-32k	41.5	37.3	31.7	26.9	-	-
LLaMA-3-8B-Instruct	58.0	56.1	-	-	-	-
T-lite-instruct-0.1	61.4	53.2	-	-	-	-
Saiga-LLaMA-3-8B	59.3	53.9	-	-	-	-
LLaMA-3-8B	56.1	49.5	-	-	-	-
Mistral-7B-v0.1	51.0	44.9	-	-	-	-
ChatGLM2-6B-32k	30.5	25.9	23.6	16.2	-	-
LongAlpaca	28.1	24.4	19.9	15.5	-	-

Table 2: The evaluation scores of various models across different context lengths.

Tasks

Complexity groups

- **The first complexity group (I)** includes tasks that require finding a short text fragment in long textual paragraphs containing irrelevant information.
- **The second complexity group (II)** includes tasks that require answering the question based on a relevant context.
- **The third complexity group (III)** includes tasks requiring inference and reasoning across input fragments rather than direct answer extraction from the text.
- **The fourth complexity group (IV)** includes tasks that require understanding the whole context and solving mathematical problems.

	Task Name	Data Origin	Skills	Metric	Dataset Size
I	Passkey	New	Reasoning	EM	1200
	PasskeyWithLibrusec	New	Reasoning	EM	1200
II	MatreshkaNames	New	Dialogue Context, Reasoning	EM	900
	MatreshkaYesNo	New	Dialogue Context, Reasoning	EM	1799
	LibrusecHistory	New	Reasoning	EM	128
	ruSciAbstractRetrieval	New	Reasoning	EM	1240
	ruQuALITY	Translated	Reasoning	EM	202
III	LongContextMultiQ	New	Reasoning	EM	1200
	LibrusecMHQA	New	Reasoning	EM	384
	ru2WikiMultihopQA	Translated	Reasoning	EM	300
	ruBABILongQA1	New	Reasoning	EM	600
	ruBABILongQA2	New	Reasoning	EM	600
	ruBABILongQA3	New	Reasoning	EM	600
	ruBABILongQA4	New	Reasoning	EM	600
	ruBABILongQA5	New	Reasoning	EM	600
IV	ruSciPassageCount	New	Reasoning	EM	600
	ruQasper	Translated	Reasoning	F1	203
	ruGSM100	Translated	Math, Logic	EM	100

Table 3: The LIBRA tasks outline. The numbers **I**, **II**, **III**, and **IV** in the left column indicate the complexity group of the tasks.

Takeaways and Key findings

- **Group I** The tasks from this group are relatively simple, and most models pass them well within their maximum input length.
- **Group II** MatreshkaYesNo, turns out to be the most straightforward task in the group, which all models cope with naturally. The ruQuALITY task is of medium complexity; several models achieved good scores on them. The classic QA task LibrusecHistory is effectively handled by modern models. The most complex task in this group is MatreshkaNames.
- **Group III** For tasks from ruBABILong, an increase in context leads to worse results. ruBABILongQA2 and ruBABILongQA3 turn out to be significantly more complex than others. The length of the context plays a significant role; as it grows, quality rapidly declines for all but the strongest models.LibrusecMHQA turns out to be a complex dataset; the maximum quality of the models for solving this problem is only 52.9.
- **Group IV** ruSciPassageCount is the most difficult task created from scratch, which all models except GPT-4o handle poorly;results are highly sensitive to context size. Most models fail to cope with ruQasper for complex tasks and domains and with mathematical problems from ruGSM100.

Takeaways:

- GPT-4o stands out among others, significantly exceeding its closest competitor GLM4-9B-Chat.
- SFT models generally perform better than the pretrained ones.
- In most cases, an increase in the input length negatively affects the model results on the task.

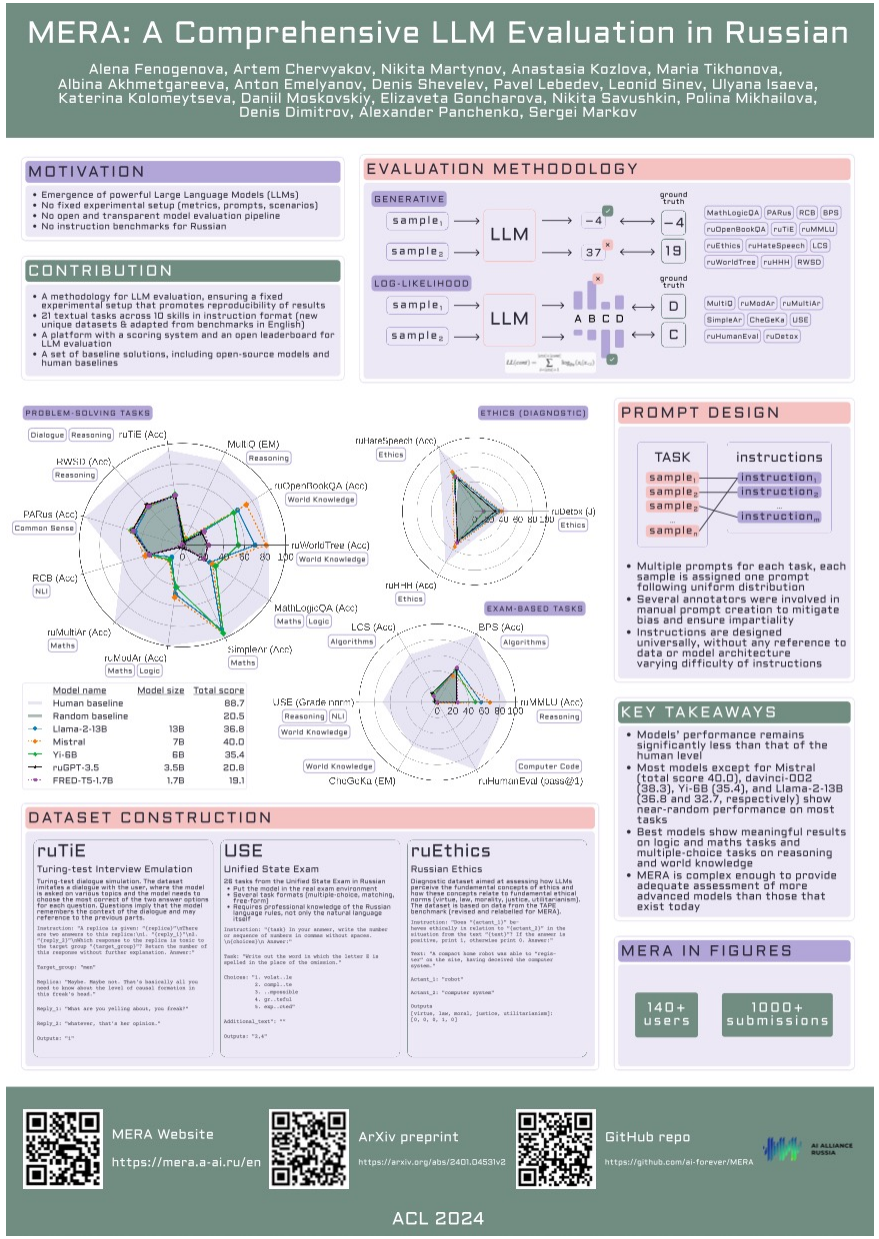
Overall, the results indicate that our **prior division of tasks into groups is highly correlated with their complexity**.

EMNLP 2025 / Suzhou, China

Постер Figma

Рекомендации:

- для тех, кто любит и умеет
- детально продумывайте визуализации
- заложите достаточно времени





Не проспи дедлайн!

Важные даты:

- дедлайн camera-ready
  - на сайте конференции
  - присылают в почте вместе с поздравлением о принятии
- дедлайн по загрузке материалов
  - зависит от трека/воркшопа
  - постоянно мониторим почту
- дедлайн по регистрации спикера от статьи (неочевидный)
  - написан на сайте **мелкими буквами**
- **[NEW!] SOLD OUT** билетов на конференцию

.





Deadlines:

- Main Conference, Findings, CL/TACL, Demos, Industry papers → October 3, 2025
- Workshops → October 6, 2025 (early registration deadline; after this, fees increase).

Не пропустите дедлайн регистрации спикера от статьи – его часто пишут мелкими буквами!

Вооружились постером – едем на конференцию



Выступление с постером это вам не шуточки

Чек-лист:

- продумайте когда и как печатать постер (на месте VS заранее)
- убедитесь, что постер распечатан корректно
- ДО конференции посмотрите время постера в расписании
- перечитайте статью перед выступлением
- [optional] киньте анонс-приглашение в чат других участников
- оденьте удобную обувь и возьмите бутылку воды
- придите на точку заранее (15-20 минут)
- найдите стенд и повесьте постер
- расскажите всем, кто про ваш крутой Research =)
- не забудьте снять постер

.



Рекомендации по выступлению

- на презентации
  - удобная обувь
  - одежда под температуру в зале
  - бутылка воды
- **не стойте с грустной миной** – улыбайтесь
- говорите и вовлекайте людей в диалог
- не бойтесь говорить, не обращайте внимание на ошибки
- не переходите на русское общение с другими коллегами
- не бросайте постер в одиночестве



Будьте улыбчивы и проактивны. Забудьте про то, что вы интроверт!

Вы здесь, что рассказать про свою работу
Рекламируйте! Общайтесь! Вовлекайте! Обменивайтесь контактами!

Особенности Oral talk/Demo

Oral talk (aka доклад):

- принципиально не отличается от обычного доклада (НА АНГЛИЙСКОМ)
- можно взять презентацию из видео (+ доработки)
- перед выступлением проверьте наличие презентации на компьютере
- не выходите за тайминг

.



Demo:

- показ со своего ноутбука
- демонстрация сайта/системы и т. п. с проектом
- не всегда есть рядом розетка => зарядите

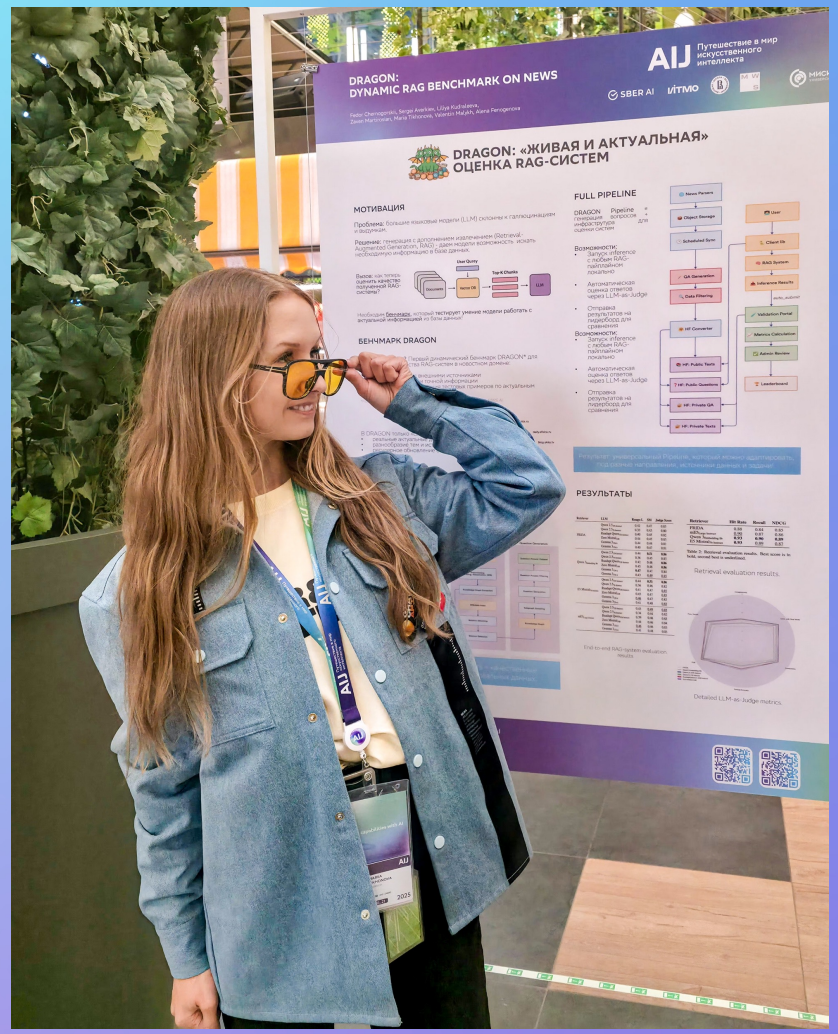
.

Но не постером единым...

Конференции – это про нетворкинг и общение с ведущими учеными.
Берите максимум от него!






DRAGON:
DYNAMIC RAG BENCHMARK ON NEWS
AIJ
Путешествие в мир искусственного интеллекта
SBER AI
ИТМО
DRAGON: «ЖИВАЯ И АКТУАЛЬНАЯ» ОЦЕНКА RAG-СИСТЕМ
МОТИВАЦИЯ
БЕНЧМАРК DRAGON
FULL PIPELINE
РЕЗУЛЬТАТЫ

Вопросы?